

	Especificação de Projeto	
	DISCIPLINA: Machine Learning I	PERÍODO: 2026.1
		UNIDADE: 2a

1. Introdução

Este projeto visa o desenvolvimento de uma solução completa de aprendizado de máquina, contemplando desde a análise exploratória de dados até a disponibilização da solução em ambiente replicável.

O objetivo é aplicar conceitos de modelagem, validação e análise de dados, aliados a práticas de MLOps, incluindo rastreamento de experimentos, deploy de modelos e reprodutibilidade do ambiente.

O projeto deverá ser desenvolvido em grupos e corresponde a 60% da nota da segunda unidade, sendo avaliado com base na qualidade técnica da solução e na apresentação final.

2. Objetivos

Desenvolver uma solução de Machine Learning que atenda aos seguintes requisitos:

- Leitura e análise exploratória de dados (EDA)
- Construção de visualizações analíticas
- Aplicação de estratégias de validação
- Treinamento e comparação de modelos de ML
- Rastreamento de experimentos com MLflow
- Desenvolvimento de dashboard interativo (ex: Streamlit, Dash, Google Looker)
- Containerização da solução com Docker

3. Avaliação

3.1. Critérios de Avaliação:

A avaliação do projeto será baseada nos seguintes critérios:

- Qualidade da análise de dados (EDA)
- Clareza e relevância das visualizações
- Correção metodológica das estratégias de validação
- Qualidade da modelagem e escolha de métricas
- Uso adequado de ferramentas de MLOps
- Funcionalidade do dashboard
- Reprodutibilidade via Docker

- Clareza e organização do relatório (**uso obrigatório do template SBC anexo**)

Dessa forma, a nota final será calculada com base nos seguintes blocos e respectivos pesos:

Bloco	Peso
Análise de Dados	15%
Modelagem e Validação	30%
MLOps (integração)	25%
Comunicação (relatório + clareza)	20%

4. Requisitos Técnicos

O projeto deverá atender aos seguintes requisitos:

- **Dados e Análise:** Leitura de base de dados; Estatísticas descritivas; Tratamento de dados.
- **Visualização:** Mínimo de 5 visualizações com interpretação
- **Validação:** Holdout; Validação cruzada; Leave-One-Out (quando aplicável). Deve ser justificada a estratégia escolhida.
- **Modelagem:** Treinamento de pelo menos dois modelos usando métricas apropriadas: KNN; Árvore de Decisão; Random Forest. É permitido usar um modelo adicional não discutido na disciplina.
- **MLflow:** Registro de parâmetros; Registro de métricas; Múltiplos experimentos; Salvamento do modelo.
- **Dashboard:** Interface interativa; Visualização de métricas; Visualização de previsões. Não só podem como devem incluir métricas relacionadas à solução apresentada em Projeto 3.

5. Entregas

- **Entrega 1:** 20/05 - Definição do problema + dataset + repositório
- **Entrega 2:** 27/05 - EDA + visualizações
- **Entrega 3:** 03/05 - Modelagem + validação + MLflow
- **Entrega Final:** 10/06 - Projeto completo + dashboard + Docker
- **Apresentação final:** 17/06 - Demonstração da solução

6. Estrutura do Repositório

A estrutura sugerida de pastas para o repositório no Github é apresentada a seguir. No entanto, ajustes podem ser aplicados para atender a proposta de cada grupo:

```
/
|— data/ # Dados
|— notebooks/ # EDA e experimentos
|— src/ # Código de treinamento
|— app/ # Dashboard
|— mlruns/ # MLflow
|— Dockerfile
|— requirements.txt
|— README.md
```

O arquivo README .md deverá conter as seguintes informações:

1. Nome e sobrenome dos membros do projeto e seus respectivos **usuários no GitHub (@fulano, @beltrano, @sicrano)**.
2. Nome da disciplina: **Machine Learning I e Projeto 3**.
3. Nome da instituição de ensino: **CESAR School**.
4. Nome da solução desenvolvida (sejam criativos).
5. Instruções detalhadas para compilar e executar.
6. Breve descrição da solução, incluindo link para o Google Sites do projeto.

Bom trabalho!